

AAAI 2027 研究方案：基于二维认知不确定性建模的 DeepWide 搜索智能体

1. 核心动机与问题定义 (Motivation & Problem Definition)

1.1 背景与痛点

近年来，大语言模型（LLMs）驱动搜索智能体（Search Agents）经历了从**深度搜索（Deep Search）** 1 2 到**广度搜索（Wide Search）** 3 4 的演进。深度搜索要求智能体通过多跳推理找到隐藏的单一答案（如 BrowseComp 5）；广度搜索要求智能体收集大规模的实体并填充结构化表格（如 WideSearch 3）。

真实的复杂任务（如绝症患者寻找匹配的临床试验）往往是**深度与广度的结合（DeepWide Search）** 6。在这类任务中，智能体不仅需要广泛地发现候选实体，还需要深入验证每个实体是否满足复杂的排他性条件。然而，当前最先进的智能体在 DeepWideSearch 基准上的成功率仅为 2.39% 6，即便是最先进的 Web2BigTable 4（在 WideSearch 上达到 38.5% 成功率）也面临着巨大的 Token 消耗问题。

1.2 真正的研究 Gap：认识论上的"不知其所不知"

深入分析 DeepWideSearch 的失败模式可以发现，智能体的失败主要源于两个极端的行为：

- 过早停止（Premature Stopping / Under-retrieval）**：智能体只找到了部分实体，或者只验证了部分属性，就以为任务完成了。
- 对冲行为（Hedging / Over-reliance on Internal Knowledge）**：智能体在找不到信息时，盲目使用内部参数知识填表，导致产生幻觉。

这两个失败模式的本质是一个**认识论（Epistemological）问题**：当前的搜索智能体无法感知自身搜索状态的**完整性（Completeness）**和**可信度（Credibility）**。正如 Agentic Uncertainty Quantification (AUQ) 7 论文所指出的，智能体在长视距任务中容易陷入"幻觉螺旋"（Spiral of Hallucination），因为早期的认知错误会作为事实被写入上下文中。

现有的不确定性量化方法（如 QuCo-RAG 8、Semantic Entropy 9）大多针对**单次生成或单线深度搜索**。在 DeepWide 场景中，不确定性是**二维的**：

- 宽度不确定性（Width Uncertainty）**：我是否已经找到了所有的候选实体？搜索空间是否已经饱和？
- 深度不确定性（Depth Uncertainty）**：对于已经找到的实体，我提取的属性是否准确且有充分的证据支撑？

本文的核心研究问题是：如何在**不进行昂贵 RL 训练**的情况下，让智能体在推理时（Inference-time）**动态感知这两种不确定性**，并利用它们在**"探索新实体（宽搜）"**和**"验证已知实体（深搜）"**

搜)"之间进行最优的资源分配?

2. 核心创新点 (Key Contributions)

本方案提出一个 Training-free 的框架——**U-DeepWide (Uncertainty-aware DeepWide Search)**，包含三个相互支撑的创新点，分别解决二维不确定性估计、深搜验证和宽搜停止的问题。

创新点一（框架层）：基于语义熵与轨迹覆盖率的二维不确定性联合建模

我们摒弃了传统的"先宽后深"或固定的 Multi-agent 流程，将 DeepWide 搜索建模为一个在二维不确定性空间中的马尔可夫决策过程。

- 深度不确定性 (Depth Uncertainty, U_d)**：采用语义熵 (Semantic Entropy) ⁹ 的思想。对于表格中的某个单元格，如果智能体基于不同搜索路径提取出的答案在语义上存在冲突，则 U_d 高。
- 宽度不确定性 (Width Uncertainty, U_w)**：引入轨迹覆盖率 (Trajectory Coverage)。借鉴信息觅食理论 (Information Foraging) ¹⁰，如果最近 K 次广度搜索请求 (Query) 返回的实体都是已存在于表格中的实体（即信息增益递减），则认为搜索空间接近饱和， U_w 降低。

动态路由策略：在每一步，智能体计算当前表格的总体 U_w 和每个实体的 U_d 。如果 U_w 高于阈值，分配 Token 预算生成新的广度 Query；如果某个实体的 U_d 高，触发**对抗性深搜验证**（见创新点二）；当两者都低于阈值时，触发停止机制（见创新点三）。

创新点二（深搜层）：对抗性自我验证 (Adversarial Self-Verification)

在深度搜索中，现有的验证机制通常是"再搜一次看结果是否一致"（如 Asymmetric Verification ¹¹）。这容易导致证实偏差 (Confirmation Bias)。

我们提出一种主动的**对抗性验证**机制：

当一个实体的某个属性被初步填充后（例如：临床试验 A 允许脑转移患者），智能体不直接接受，而是被强制要求生成一个**证伪查询 (Falsification Query)**（例如搜索："临床试验 A 排除 脑转移"）。

只有当证伪查询无法找到可靠的反驳证据时，该属性的 U_d 才会被显著降低。这种机制模仿了科学研究中的对照实验思想，能极大地抑制智能体对内部知识的过度依赖 (Overreliance on Internal Knowledge)。

创新点三（宽搜层）：基于"信息增益衰减"的最优停止准则 (Optimal Stopping Criteria)

宽搜中最难的问题是"何时停止"。现有的 Table-as-Search ¹² 依赖 LLM 主观判断表格是否"填满"，这在实体数量未知时完全失效。

我们提出一种基于**边际信息增益 (Marginal Information Gain)** 的严格停止准则。我们将每次宽搜视为一次采样。定义信息增益 IG_t 为第 t 次搜索发现的新实体数量除以该次搜索消耗的 Token 数。

随着搜索进行, IG_t 会呈现指数衰减。当 IG_t 的移动平均值低于动态计算的成本阈值 (由剩余的总体 Token 预算决定) 时, 系统触发**最优停止 (Optimal Stopping)**。这确保了智能体不会在已经枯竭的搜索方向上浪费昂贵的 API 成本。

3. 实验设计与预期结果 (Experimental Design)

3.1 评估基准与对比基线

- **核心 Benchmark:** DeepWideSearch 6 (包含 Wide2Deep 和 Deep2Wide 子集, 最能体现深广度结合的难度)。
- **辅助 Benchmark:** WideSearch 3 (测试纯广度)、BrowseComp 5 (测试纯深度)。
- **Baselines:**
 - *Agentic Frameworks:* ReAct 13、Table-as-Search (TaS) 12、Web2BigTable 4 (若开源)。
 - *RL-trained Agents:* Search-R1 14、WebSailor 15、Marco DeepResearch 16。

3.2 核心实验与评估指标

- **综合性能评估:** 报告 Success Rate (SR)、Row F1、Item F1 和 Column F1。预期 U-DeepWide 在 SR 上能实现数倍于现有 SOTA (如 Marco DeepResearch 的 2.39%) 的提升。
- **成本-效益分析 (Cost-Efficiency Pareto Frontier):** 这是本文的一大亮点。我们将绘制横轴为 Token Cost, 纵轴为 Item F1 的帕累托前沿曲线。预期 U-DeepWide 由于引入了最优停止准则, 能在消耗不到 Baseline 一半 Token 的情况下, 达到同等或更高的 F1 分数。

3.3 消融实验 (Ablation Studies)

- **w/o 对抗性验证:** 替换为普通的重复搜索验证, 预期在 Deep2Wide 子集上 Precision 显著下降 (幻觉增加)。
- **w/o 边际信息增益停止:** 替换为固定步数停止, 预期 Token Cost 大幅上升, 且在实体较少的任务上发生 Context Overflow。

4. 结论与 AAI 竞争力分析

本方案精准击中了当前 DeepResearch 领域向真实复杂场景演进时的核心痛点——**二维不确定性管理与预算分配**。

相比于今年大量堆砌 Multi-agent 或进行昂贵 RL 训练的增量工作，本方案的 Training-free 属性、坚实的认识论基础（对抗性验证）以及严谨的数学建模（边际增益最优停止），使其在理论深度和实际效用（降低 Token 成本、提高准确率）上都具备极强的竞争力，非常契合 AAAI 2027 对基础算法创新与实际应用结合的偏好。

References

- [1] Li, X., et al. (2025). Search-o1: Agentic Search-Enhanced Large Reasoning Models. arXiv:2501.05366.
- [2] Zheng, Y., et al. (2025). DeepResearcher: Scaling Deep Research via Reinforcement Learning in Real-world Environments. arXiv:2504.03160.
- [3] Wong, R., et al. (2025). WideSearch: Benchmarking Agentic Broad Info-Seeking. arXiv:2508.07999.
- [4] Huang, Y., et al. (2026). Web2BigTable: A Bi-Level Multi-Agent LLM System for Internet-Scale Information Search and Extraction. arXiv:2604.27221.
- [5] Wei, J., et al. (2025). BrowseComp: A Simple Yet Challenging Benchmark for Browsing Agents. arXiv:2504.12516.
- [6] Lan, T., et al. (2025). DeepWideSearch: Benchmarking Depth and Width in Agentic Information Seeking. arXiv:2510.20168.
- [7] Zhang, J., et al. (2026). Agentic Uncertainty Quantification. arXiv:2601.15703.
- [8] Min, D., et al. (2025). QuCo-RAG: Quantifying Uncertainty from the Pre-training Corpus for Dynamic Retrieval-Augmented Generation. arXiv:2512.19134.
- [9] Farquhar, S., et al. (2024). Detecting hallucinations in large language models using semantic entropy. *Nature*, 630(8017), 625-630.
- [10] Qian, H., & Liu, Z. (2025). Scent of Knowledge: Optimizing Search-Enhanced Reasoning with Information Foraging. arXiv:2505.09316.
- [11] Zeng, W., et al. (2026). Pushing Test-Time Scaling Limits of Deep Search with Asymmetric Verification. ICLR 2026.
- [12] Lan, T., et al. (2026). Table-as-Search: Formulate Long-Horizon Agentic Information Seeking as Table Completion. arXiv:2602.06724.
- [13] Yao, S., et al. (2022). ReAct: Synergizing Reasoning and Acting in Language Models. ICLR 2023.
- [14] Jin, P. G., et al. (2025). Search-R1: Training LLMs to Reason and Leverage Search Engines with Reinforcement Learning. arXiv:2503.09516.
- [15] Li, K., et al. (2025). WebSailor: Navigating Super-Human Reasoning for Web Agent. arXiv:2507.02592.
- [16] Zhu, B., et al. (2026). Marco DeepResearch: Unlocking Efficient Deep Research Agents via Verification-Centric Design. arXiv:2603.28376.